

Assistente Inteligente com IA, RAG e Automação

Secretária Virtual de Agendamento — Clínica Odontológica Rosa Leal

Parte 1 — Contextualização

Cenário: Secretária virtual de agendamento para a Clínica Odontológica Rosa Leal. O assistente não trata de nenhum assunto clínico — sua função é exclusivamente agendar, remarcar e cancelar consultas, além de responder dúvidas básicas e pré-aprovadas sobre a rotina de atendimento.

1. Qual problema o assistente resolverá?

O WhatsApp da clínica recebe um volume alto de mensagens repetitivas — pedidos de agendamento, dúvidas sobre horário de funcionamento, duração média de procedimentos, convênios aceitos e o que levar na consulta — que sobrecarregam a recepção e atrasam respostas a casos que realmente precisam de atenção humana.

2. Quem utilizará o sistema?

Pacientes (via WhatsApp), que agendam e tiram dúvidas; e a Dra. Rosa Leal, que recebe notificações apenas quando surge uma pergunta fora do escopo pré-programado.

3. Quais benefícios a IA trará?

- Agendamento disponível 24 horas por dia, sem depender da recepção estar online.
- Respostas padronizadas e consistentes para as dúvidas mais frequentes.
- Redução imediata do volume de mensagens que chegam ao WhatsApp da clínica.
- A doutora só é acionada quando a pergunta realmente exige seu conhecimento — sem ela precisar filtrar mensagens repetitivas.

Parte 2 — Engenharia de Prompt

Prompt estruturado com os 5 elementos exigidos: papel, contexto, tarefa, formato da resposta e restrições.

[ROLE]

Você é a secretária virtual da Clínica Odontológica Rosa Leal.
Tom cordial, objetivo e eficiente, como uma recepcionista experiente cuidando da agenda da doutora.

[CONTEXTO]

Você tem acesso a uma base de conhecimento vetorizada contendo APENAS: horários de atendimento, duração média dos principais procedimentos, convênios aceitos, valores de referência, política de remarcação/cancelamento e o que o paciente deve levar na consulta. Você não trata de nenhum assunto clínico (sintomas, diagnóstico, dor, tratamento).

[TAREFA]

1. Se a pergunta estiver coberta pela base de conhecimento, responda diretamente com a informação.
2. Se o paciente quiser agendar, remarcar ou cancelar, consulte a disponibilidade no Google Calendar e confirme o horário.
3. Se a pergunta for clínica ou não estiver na base de conhecimento, NÃO tente responder. Informe que a dúvida é mais específica e será repassada à Dra. Rosa Leal.

[FORMATO DA RESPOSTA]

- Resposta curta e objetiva, no máximo 3 frases.
- Ao confirmar agendamento, sempre repita data e horário.
- Ao escalonar, use o texto padrão: "Essa é uma dúvida mais específica – vou repassar para a Dra. Rosa Leal, que te responde em breve por aqui."

[RESTRIÇÕES]

- Nunca comente sintomas, diagnóstico ou tratamento.
- Nunca invente informações fora da base de conhecimento.
- Nunca solicite dados sensíveis (CPF completo, cartão) via chat.
- Nunca prometa um horário sem checar a disponibilidade real.

Parte 3 — Arquitetura da Solução

Diagrama contendo os seis elementos obrigatórios: usuário, frontend React, backend Java, modelo de IA, banco vetorial e base de conhecimento.




Figura 1 — Arquitetura da secretária virtual de agendamento

Fluxo completo da pergunta até a resposta

O paciente envia a mensagem pelo frontend (chat web ou WhatsApp), que encaminha via HTTP para o backend Java. O backend transforma a pergunta em um vetor (embedding) e consulta o banco vetorial, que busca os trechos mais similares dentro da FAQ de agendamento da clínica. Os trechos recuperados são injetados no prompt junto com a pergunta original e enviados ao modelo de IA, que gera a resposta ou identifica que o caso deve ser escalonado. A resposta retorna pelo backend até o frontend, onde o paciente a recebe.

Parte 4 — RAG e Embeddings

a) O que é RAG (Retrieval-Augmented Generation)?

Técnica em que, antes de o LLM gerar a resposta, o sistema busca (retrieve) trechos relevantes de uma base de conhecimento externa e os injeta no prompt como contexto. Isso ancora a resposta em dados reais e atualizados da clínica, em vez de depender apenas do que o modelo aprendeu no treinamento.

b) O que são embeddings?

São representações numéricas (vetores de N dimensões) de um texto, em que textos com significado semântico parecido ficam próximos no espaço vetorial. É assim que perguntas como "quero mudar o horário da minha consulta" e "posso remarcar?" podem ser reconhecidas como equivalentes, mesmo sem compartilhar as mesmas palavras.

c) Como ocorre a busca semântica?

A pergunta do paciente é convertida em um vetor; esse vetor é comparado, geralmente por similaridade de cosseno, contra os vetores dos itens já indexados na FAQ. Os itens com maior similaridade são retornados como contexto, junto com um score numérico que indica o quão relevante é aquele resultado.

d) Por que o uso de RAG reduz alucinações dos LLMs?

Porque o modelo passa a responder com base em informações reais da FAQ da clínica, em vez de gerar conteúdo apenas a partir de padrões estatísticos aprendidos no treinamento. Ao restringir o prompt a responder somente com base no contexto fornecido — e a escalonar quando não há contexto suficiente — reduz-se drasticamente o risco de o modelo inventar horários, valores ou políticas que não existem.

Parte 5 — Automação com n8n

Workflow com as cinco etapas obrigatórias — trigger, consulta à base de conhecimento, chamada ao modelo de IA, salvamento do atendimento e notificação — acrescido de uma etapa de decisão que direciona entre agendamento automático e escalonamento para a doutora.




Figura 2 — Workflow de automação no n8n com decisão de escalonamento

Função de cada etapa

- Trigger (Webhook): ponto de entrada do workflow. Recebe a mensagem do paciente vinda do WhatsApp ou site, disparando a execução.
- Consulta à FAQ vetorizada: o node de embedding transforma a pergunta em vetor e busca por similaridade na base de conhecimento, retornando o trecho mais relevante junto com um score de confiança.
- Chamada ao modelo de IA: o modelo recebe a pergunta e o contexto recuperado, e classifica a intenção — dúvida de FAQ, pedido de agendamento, ou fora do escopo.
- Decisão (score de similaridade): um node IF verifica se o score retornado é suficiente. Se sim, o fluxo segue para checar disponibilidade no Google Calendar e confirmar o horário. Se não, o fluxo segue para notificar a Dra. Rosa Leal.
- Salvamento do atendimento e notificação: o registro é gravado no banco de dados (pergunta, resposta, timestamp, paciente) e o paciente recebe a confirmação do agendamento ou o aviso de que a dúvida foi repassada à doutora.

Parte 6 — Aplicação Avançada

Funcionalidade adicional escolhida: IA Generativa.

Entrada

Um evento de agendamento confirmado no Google Calendar, contendo nome do paciente, procedimento e horário marcado.

Processamento

Um workflow agendado no n8n roda algumas horas antes de cada consulta, buscando os agendamentos do dia seguinte. Para cada um, o modelo de IA generativa cria uma mensagem de lembrete personalizada, adaptando o tom e incluindo orientações relevantes (ex: chegar 10 minutos antes, levar documento e carteirinha do convênio).

Resultado esperado

O paciente recebe, automaticamente, uma mensagem de lembrete natural e personalizada no WhatsApp, reduzindo a taxa de faltas e reforçando a experiência de atendimento sem exigir qualquer ação manual da recepção.